

Estimación del nivel de obesidad basado en hábitos alimenticios y condición física.

Mily Johanna Sierra Soto

Departamento de Ingeniería de Sistemas

Universidad de Antioquia

Medellín, Colombia

mily.sierra@udea.edu.co

Luisa María Soto Arias

Departamento de Ingeniería de Sistemas

Universidad de Antioquia

Medellín, Colombia

luisa.soto1@udea.edu.co

Resumen—La obesidad se ha convertido en un tema de salud pública en los últimos años, por lo que es necesario estudiar los factores determinantes en el desarrollo de esta enfermedad. En este estudio se utilizaron técnicas de Machine Learning para predecir el nivel de obesidad de las personas basándose en hábitos alimenticios, actividad física, y otras características. Se compararon seis modelos: Regresión Logística, KNN, Random Forest, Gradient Boosting, Redes Neuronales y Máquina de Vectores de Soporte, utilizando el dataset ObesityDataSet. El mejor resultado fue obtenido por Random Forest y Gradient Boosting con un accuracy de 91 % sobre el conjunto de test, superando a los demás en todas las métricas.

Palabras clave—Obesidad, Machine Learning, Modelos, Métricas

I. INTRODUCCIÓN

La obesidad representa uno de los mayores desafíos de salud pública a nivel mundial. Según la Organización Mundial de la Salud (OMS), se define como la acumulación excesiva del tejido adiposo en el organismo, lo cual conlleva a riesgos para la salud. Una persona con un índice de masa corporal (IMC) superior a 30 es clasificado como obeso, mientras que valores entre 25 y 30 se considera en sobrepeso. Desde 1997, la OMS reconoció la obesidad como una epidemia global y uno de los principales problemas de salud pública a nivel mundial [1].

Ante este panorama, los sistemas automatizados de clasificación del nivel de obesidad surgen como herramientas de alto valor clínico y preventivo. La identificación temprana del riesgo de obesidad, apoyadas en técnicas de Inteligencia Artificial, permite a los profesionales de la salud diseñar intervenciones personalizadas y oportunas.

El presente proyecto tiene como objetivo desarrollar una solución mediante la aplicación de técnicas de Machine Learning aprendidas en clase, utilizando la base de datos “Estimation of Obesity Levels Based on Eating Habits and Physical Condition” [2]. Este dataset ha sido utilizado en la literatura científica, lo que respalda su pertinencia y permite comparar con resultados reportados en el estado del arte.

El dataset fue recopilado y publicado en 2019 y se encuentra disponible en el repositorio UCI Machine Learning Repository. Contiene información sobre hábitos alimenticios, actividad física y condición general de individuos provenientes de Colombia, México y Perú.

El problema se aborda como un problema de clasificación supervisada multiclase, dado que la variable objetivo NOesity presenta siete categorías discretas y ordenadas. Se dispone de etiquetas para todas las muestras del dataset, lo que hace del aprendizaje supervisado el paradigma apropiado.

II. ESTADO DEL ARTE

Este tema en específico ha sido altamente estudiado desde diferentes perspectivas, una de las razones principales es su relación directa con la salud de las personas. En especial, hay muchos trabajos desde el área de Machine Learning que han tenido como objetivo la estimación del nivel de obesidad basándose en una gran cantidad de features, que finalmente actúan como la fuente de información para los diversos modelos planteados.

Cui et al. realizaron un estudio sobre el nivel de obesidad [3] teniendo como fuente de información la base de datos que utilizaremos durante todo este proyecto. El desarrollo de este trabajo se fundamentó en el aprendizaje supervisado, específicamente en un problema de clasificación utilizando 5 modelos: Árbol de Decisión, Regresión Logística, Vecino más Cercano, Random Forest y Máquina de Vectores de Soporte.

Aunque en el artículo se mencionan técnicas de validación interna como el GridSearchCV, en ningún momento se especifica la estrategia de partición de datos y el desempeño fue evaluado únicamente con Accuracy, lo que puede ser un poco reduccionista y limitante a la hora de hacer la comparativa [1]. Finalmente, los autores llegan a la conclusión de que los modelos basados en Árboles de Decisión, específicamente los que incorporan técnicas de ensamble como XGBoost y LightGBM presentan un mejor desempeño.

Por otro lado, Karakoç y Oruç trabajaron en un proyecto [4] con el mismo objetivo: encontrar un modelo para predecir el nivel de obesidad basándose en la misma base de datos, bajo el aprendizaje supervisado. A diferencia del trabajo anterior, la propuesta de estos autores fue un modelo de ensamble, el cual utiliza diversos clasificadores: Árbol de Decisión, Redes Neuronales, Vecino más Cercano, Naive Bayes e incorpora un modelo de tipo ensamble (SVM-based ensemble), lo que nos permite analizar diversas técnicas y tener más fundamentación a la hora de implementar nuestra propuesta.

Inicialmente realizaron la limpieza de los datos y la normalización, así como la división de estos de la manera más conocida: (80 % train y 20 % test). A diferencia del trabajo anterior, Karakoç y Oruç realizaron la evaluación del desempeño bajo las métricas de accuracy, precisión, recall-sensitivity y F1-Score.

Finalmente, como resultado, obtuvieron que de manera individual los modelos con mejores resultados fueron el Ensamblado basado en SVM y la Red Neuronal. Y el modelo híbrido tuvo el mejor rendimiento, superando el 94 % en todas las métricas. Este resultado da como prueba lo robusto que puede llegar a ser un modelo de ensamble si se utilizan los clasificadores adecuados para el tipo de problema [2].

Gozukara Bag et al. [5] abordaron la clasificación de niveles de obesidad como un problema de aprendizaje supervisado, comparando Regresión Logística, Random Forest y XGBoost sobre la misma base de datos de este proyecto. Para la validación usaron una partición 75 % para train y 25 % para test, con una subdivisión interna del conjunto de entrenamiento de la forma más común para optimización y validación, lo que les permitió tener una estimación más confiable del desempeño. Las métricas que reportaron fueron precisión, recall, accuracy, F1-score y AUC, un conjunto bastante completo que va más allá del accuracy simple y permite entender mejor el comportamiento del modelo frente a las siete clases de obesidad.

Lo más interesante de este trabajo es que la Regresión Logística superó a los demás modelos con un accuracy de 98.99 %, mientras que Random Forest y XGBoost obtuvieron accuracies de 96.17 % y 95.77 % respectivamente. Esto indica que para esta base de datos, un modelo paramétrico simple puede ser muy competitivo, lo que respalda nuestra decisión de incluirlo en nuestro proyecto. Sin embargo, el hecho de que no usaran cross-validation limita qué tan generalizables son sus conclusiones, una limitación que en nuestro proyecto buscamos superar mediante validación cruzada aplicada sobre múltiples subconjuntos de características.

Por último, en [6] se compararon seis algoritmos de aprendizaje supervisado sobre la misma base de datos: LightGBM, XGBoost, Random Forest, Árboles de Decisión, Árboles Extremadamente Aleatorios y Regresión Logística, siguiendo una estrategia de partición similar a la de los trabajos anteriores. La variedad de modelos evaluados da una visión amplia de qué tipo de algoritmos funcionan mejor para este problema, y en general los resultados muestran que los métodos de boosting tienen ventaja con las bases de datos de este estilo. Las métricas usadas coinciden con las de [5], lo que facilita comparar resultados entre proyectos.

El mejor resultado lo obtuvo LightGBM con un accuracy de 97.45 % y un AUC de 0.9990, superando a todos los demás modelos incluyendo la Regresión Logística, lo que contrasta con lo encontrado en [5] y muestra que el modelo óptimo puede variar según la forma experimental. Este resultado nos sirve como referencia para evaluar qué tan competitivos son nuestros modelos y además motiva explorar diferentes subconjuntos de características.

III. METODOLOGÍA

III-A. Análisis del dataset

Inicialmente, se realizó un análisis exploratorio de datos con el propósito de comprender la estructura y características principales del conjunto de datos utilizados en el estudio. Allí, se evidenció:

- **Número de registros:** 2,111.
- **Número de variables:** 16 variables independientes y 1 variable dependiente (NObesity)

Es relevante señalar que el 77 % de los registros fueron generados de forma sintética mediante la herramienta Weka con el filtro SMOTE, mientras que el 23 % restante proviene de encuestas reales recolectadas a través de una plataforma web.

- **Variables del Dataset:** En las siguientes tablas se presentan de manera detallada el tipo de dato y la descripción de la variable:

Tabla I
VARIABLES CATEGÓRICAS DEL DATASET

Variable	Descripción
Gender	Sexo biológico del individuo
CAEC	Consumo de alimentos entre comidas
CALC	Frecuencia de consumo de alcohol
MTRANS	Medio de transporte habitual

Tabla II
VARIABLES BINARIAS DEL DATASET

Variable	Descripción
family_history_with_overweight	Antecedentes familiares de sobrepeso
FAVC	Consumo frecuente de alimentos hipercalóricos
SMOKE	Hábito de fumar
SCC	Monitoreo de ingesta calórica

Tabla III
VARIABLES NUMÉRICAS DEL DATASET

Variable	Tipo	Descripción
Age	Continua	Edad del individuo
Height	Continua	Estatura
Weight	Continua	Peso corporal
FCVC	Ordinal	Frecuencia de consumo de vegetales en comidas
NCP	Ordinal	Número de comidas principales al día
CH2O	Ordinal	Consumo diario de agua
FAF	Ordinal	Frecuencia de actividad física semanal
TUE	Ordinal	Tiempo usando dispositivos electrónicos (horas/día)
NObesity (target)	Ordinal	Nivel de obesidad según IMC

- **Valores faltantes:** El dataset no presenta valores faltantes en ninguna de sus 17 variables. Por lo tanto, no se requiere implementar estrategias de imputación de datos para el preprocesamiento.
- **Variable objetivo:** La variable de salida NObesity corresponde al nivel de obesidad del individuo, determinado

a partir del cálculo del IMC y los criterios de clasificación de la OMS. Esta variable es de naturaleza ordinal y comprende siete clases:

- Insufficient Weight ($IMC < 18.5$)
- Normal Weight ($18.5 \leq IMC < 25.0$)
- Overweight Level I ($25.0 \leq IMC < 27.5$)
- Overweight Level II ($27.5 \leq IMC < 30.0$)
- Obesity Type I ($30.0 \leq IMC < 35.0$)
- Obesity Type II ($35.0 \leq IMC < 40.0$)
- Obesity Type III ($IMC \geq 40.0$)

- **Codificación de las variables:** Para el preprocesamiento, las variables categóricas nominales y binarias fueron codificadas mediante One-Hot Encoding. La variable objetivo NOesity fue codificada con Label Encoding. Las variables numéricas continuas fueron normalizadas con MinMax Scaler al rango $[0,1]$.

III-B. Reducción de dimensión

Este proceso se realizó en general para todos los modelos antes de su entrenamiento, con el objetivo de probar cada uno de ellos con los mismos subconjuntos de datos. Se decidió trabajar con 4: completo, filtro, PCA y LDA.

En general todos los subconjuntos parten del completo, del cual se excluye la variable objetivo y la variable “Height”, decisión que se toma porque esta variable junto a “Weight” definen el IMC, que es justamente lo que se busca predecir.

Para la selección de características se utilizó la estrategia de filtro, específicamente Anova para las variables numéricas, CHI2 para las categóricas y Mutual Information para dar soporte a las dos anteriores.




Figura 1. Comparación normalizada de ANOVA, Chi-cuadrado y Mutual Information

En la figura 1 se observa la comparación entre las tres estrategias, las cuales anteriormente se normalizaron entre 0-1. Con base en este gráfico se tomó la decisión de eliminar las variables SMOKE, FAVC y CALC, puesto que no tienen mayor impacto en la variable objetivo.

Además, se realizó una matriz de correlación entre todas las variables excluyendo a la variable objetivo con el propósito de evaluar la colinealidad entre ellas y otra posible exclusión. Sin embargo, al analizar el gráfico no se encontró alta colinealidad entre ninguna de las variables, por lo que ninguna otra fue eliminada de este subconjunto.

Para Extracción se trabajó con dos estrategias: PCA y LDA. Para PCA se buscó el conjunto de datos que explicara como mínimo el 90 % de la variabilidad de los datos, obteniendo así un conjunto de 12 componentes para el tercer subconjunto de datos.




Figura 2. Varianza explicada

En la figura 2 puede observarse que los 12 componentes explican más del 90 % de la variabilidad de los datos.

Finalmente, para LDA, tras analizar el gráfico de separación acumulada, se observó que los dos primeros componentes explican el 96 % de la separación entre clases. Sin embargo, dado el solapamiento visual observado en el scatter plot de LD1 vs LD2, se decidió conservar 4 componentes que explican el 99 % de la separación discriminante.




Figura 3. Separación acumulada




Figura 4. Scatter Plot de LD1 vs LD2

III-C. Entrenamiento y evaluación de los modelos

Como se mencionó anteriormente, se trabajaron 6 modelos: Regresión logística, KNN, Random Forest, Gradient Boosting, Redes Neuronales y Modelo de Vectores de Soporte.

La partición de datos se hizo 80 %-20 % y se utilizó gridSearch como estrategia de búsqueda de hiperparámetros, además, la validación se realizó con Cross Validation en todos los casos, ya que gridSearch la realiza internamente. Es importante aclarar que no fue necesario el uso de estrategias para el manejo del desbalance puesto que la variable objetivo no se encontraba desbalanceada al obtener que la cantidad de datos de cada etiqueta está entre 12 % y 16 %.

Cada uno de los modelos se probó con los 4 subconjuntos que se describieron anteriormente, con el objetivo de encontrar el mejor en cuanto a estrategia y datos. Por lo tanto, al final se obtuvieron 24 modelos, de los cuales se seleccionaron 5 que más adelante se explicarán.

En la siguiente tabla se presentan los hiperparámetros evaluados durante el proceso de optimización de cada modelo, junto con su descripción y la malla de valores explorada en cada caso.

- **Regresión Logística:** Para la Regresión Logística se exploraron tres hiperparámetros: C controla el nivel de regularización del modelo, valores pequeños generan modelos más simples mientras que valores grandes permiten mayor ajuste a los datos; solver define el algoritmo de optimización interno, seleccionando lbfgs y saga por ser los más adecuados para problemas multiclase; y max_iter limita el número de iteraciones para garantizar la convergencia.

Tabla IV
HIPERPARÁMETROS EVALUADOS PARA REGRESIÓN LOGÍSTICA

Hiperparámetro	Descripción	Malla de Valores
C	Inverso de la regularización	0.01, 0.1, 1, 10, 100
solver	Algoritmo de optimización	lbfgs, saga
max_iter	Máximo de iteraciones	500, 1000

- **KNN (K-Nearest Neighbors):** Para KNN se exploraron n_neighbors en un rango de valores impares para evitar empates en la votación, y metric para determinar cuál medida de distancia se adapta mejor a la naturaleza del dataset. El parámetro weights fue fijado en uniform dado que la opción distance generó sobreajuste perfecto en entrenamiento al asignar peso infinito al vecino más cercano.

Tabla V
HIPERPARÁMETROS EVALUADOS PARA KNN

Hiperparámetro	Descripción	Malla de Valores
n_neighbors	Número de vecinos	7, 9, 11, 15, 21, 25
weights	Ponderación de vecinos	uniform
metric	Métrica de distancia	euclidean, manhattan

- **Random Forest:** Este modelo utilizó una búsqueda iterativa manual explorando el número de árboles y el criterio de división. El rango de árboles se definió de 10 en 10 hasta 100 para encontrar el punto donde el modelo estabiliza su desempeño sin incrementar innecesariamente el costo computacional, y se compararon los criterios gini y entropy para determinar cuál genera mejores particiones para este dataset.

Tabla VI
HIPERPARÁMETROS EVALUADOS PARA RANDOM FOREST

Hiperparámetro	Descripción	Malla de Valores
n_estimators	Número de árboles	10, 20, 30, ..., 100
criterion	Criterio de división	gini, entropy
min_samples_leaf	Mínimo de muestras por hoja	3

- **Gradient Boosting:** Para Gradient Boosting, los hiperparámetros se optimizaron mediante GridSearchCV con 10 folds el learning_rate, que controla la contribución de cada árbol al modelo final, y n_estimators, que define el número de árboles en el ensamble. Los valores de learning_rate se exploraron en un rango amplio para analizar el efecto entre convergencia lenta pero precisa y convergencia rápida pero menos estable.

Tabla VII
HIPERPARÁMETROS EVALUADOS PARA GRADIENT BOOSTING

Hiperparámetro	Descripción	Malla de Valores
learning_rate	Tasa de aprendizaje	0.01, 0.1, 0.5
n_estimators	Número de árboles	50, 100, 150

- **Redes Neuronales:** Las Redes Neuronales fueron optimizadas con GridSearchCV usando StratifiedKFold de 5 folds. Se exploraron hidden_layer_sizes para determinar la arquitectura óptima de la red, activation para comparar funciones de activación no lineales, y alpha que controla la regularización L2 para reducir el sobreajuste.

Tabla VIII
HIPERPARÁMETROS EVALUADOS PARA REDES NEURONALES

Hiperparámetro	Descripción	Malla de Valores
hidden_layer_sizes	Arquitectura de capas ocultas	(80,80,80,80), (100,100,100,100)
activation	Función de activación	relu, tanh
alpha	Regularización L2	0.0001, 0.001, 0.01

- **Máquina de Vectores de Soporte:** Este modelo fue optimizado de la misma manera que el anterior usando StratifiedKFold de 5 folds. Se exploraron C, que controla el balance entre maximizar el margen de separación y minimizar los errores de clasificación, y kernel, que define la función usada para transformar el espacio de características. Se compararon los kernels linear y rbf, el primero para evaluar si las clases son linealmente separables y el segundo para capturar relaciones no lineales entre las variables.

Tabla IX
HIPERPARÁMETROS EVALUADOS PARA SVM

Hiperparámetro	Descripción	Malla de Valores
C	Parámetro de regularización	0.01, 0.1, 0.5, 1, 10
kernel	Función de transformación	linear, rbf

Para evaluar el desempeño de los modelos se utilizaron cuatro métricas: accuracy, precisión, recall y F1-score, todas calculadas en su variante macro. Esta variante promedia el resultado de cada una de las siete clases de obesidad con igual peso, lo cual es adecuado dado que el dataset está balanceado entre clases.

El accuracy mide la proporción de predicciones correctas sobre el total de muestras, lo que da una idea general del desempeño del modelo. Sin embargo, dado que el problema involucra siete clases, esta métrica sola puede ser insuficiente, por lo que se complementa con las demás. La precisión indica qué proporción de las predicciones positivas de cada clase fueron correctas, mientras que el recall mide qué proporción de los casos reales de cada clase fueron identificados correctamente. El F1-score combina ambas en una sola medida mediante su media armónica, siendo especialmente útil cuando se quiere un balance entre precisión y recall. Estas cuatro métricas juntas permiten tener una visión completa del comportamiento de cada modelo frente a las siete clases de obesidad.

IV. ANÁLISIS DE RESULTADOS

Después de implementar y entrenar cada uno de los modelos, se seleccionaron los 5 mejores con respecto a las métricas, entre ellos se encuentran Random Forest y Gradient Boosting con dos subconjuntos y SVM. Los resultados se encuentran en las siguientes tablas:

Tabla X
MÉTRICAS DE TEST DE LOS 5 MEJORES MODELOS

Modelo	Subconjunto	Accuracy	F1	Recall	Precision
Gradient Boosting	Completo	0.9102	0.9071	0.9066	0.9104
Gradient Boosting	Filtro	0.8913	0.8868	0.8866	0.8893
Random Forest	Completo	0.9102	0.9069	0.9064	0.9142
Random Forest	Filtro	0.9031	0.9008	0.8999	0.9086
SVM	Filtro	0.8629	0.8577	0.8588	0.8624

Tabla XI
MÉTRICAS DE VALIDACIÓN DE LOS 5 MEJORES MODELOS

Modelo	Subconjunto	Accuracy	F1	Recall	Precision
Gradient Boosting	Completo	0.9135	0.9114	0.9118	0.9151
Gradient Boosting	Filtro	0.9058	0.9044	0.9046	0.9088
Random Forest	Completo	0.9236	0.9219	0.9221	0.9296
Random Forest	Filtro	0.9077	0.9056	0.9064	0.9157
SVM	Filtro	0.8395	0.8352	0.8370	0.8381

Tabla XII
MÉTRICAS DE ENTRENAMIENTO DE LOS 5 MEJORES MODELOS

Modelo	Subconjunto	Accuracy	F1	Recall	Precision
Gradient Boosting	Completo	1.0000	1.0000	1.0000	1.0000
Gradient Boosting	Filtro	1.0000	1.0000	1.0000	1.0000
Random Forest	Completo	0.9828	0.9825	0.9823	0.9835
Random Forest	Filtro	0.9846	0.9843	0.9839	0.9853
SVM	Filtro	0.9354	0.9345	0.9344	0.9369

Como se evidencia en las anteriores tablas, las métricas se evaluaron sobre train, test y Validation. Sin embargo, a la hora de tomar la decisión, se prioriza test. Específicamente en Gradient Boosting, a pesar de que en train llega a métricas perfectas, logra generalizar bien, por lo que no se considera sobreajuste.

Al analizar los mejores modelos basados en métricas, se considera que Random Forest y Gradient Boosting son los mejores más allá de su buena capacidad de predicción, ya que permiten analizar la importancia de cada variable en la predicción, lo cual es valioso en el ámbito médico puesto que permite identificar qué factores como el peso, los hábitos alimenticios o el historial familiar tienen mayor influencia en el nivel de obesidad de un paciente.

En caso tal de tener que elegir un único modelo, Gradient Boosting presenta mejor recall en Obesity Type III (0.78 vs 0.73), que corresponde al nivel más severo de obesidad, lo cual es clínicamente relevante ya que minimiza los falsos negativos en casos graves, por lo tanto, Gradient Boosting sería el modelo recomendado.




Figura 5. Matriz de confusión para Gradient Boosting

En la Figura 5 se presenta la matriz de confusión del modelo seleccionado, Gradient Boosting con el subconjunto completo.

V. CONCLUSIONES

Al comparar los resultados obtenidos con los trabajos del estado del arte, se observa que los modelos de ensamble siguen siendo los más competitivos, lo cual es consistente con Cui et al. [3] y con [6], donde algoritmos basados en boosting como XGBoost y LightGBM obtuvieron los mejores rendimientos. En este proyecto, Random Forest y Gradient Boosting alcanzaron accuracies superiores al 91 % en test, confirmando esta tendencia.

Por otro lado, la Regresión Logística registró un 82.27 %, mucho más inferior al 98.99 % publicado en [5], esta diferencia se explica por la metodología de validación ya que mientras el trabajo citado se apoyó en una partición fija, en este proyecto se implementó validación cruzada, lo que produce cifras más realistas y confiables.

Finalmente, a diferencia de [4], donde el enfoque híbrido logró superar el 94 % en todas las métricas, los resultados de este proyecto demuestran que modelos individuales de ensamble fueron suficientes para obtener los mejores desempeños y, más allá de la complejidad de la arquitectura del modelo, la calidad y el tratamiento estratégico de los subconjuntos de características desempeñan un papel fundamental en el éxito de la predicción.

REFERENCIAS

- [1] Sociedad Chilena de Obesidad (SOCHOB), "La obesidad es una enfermedad", 2022. Disponible en: <https://www.sochob.cl/web1/la-obesidad-es-una-enfermedad/>.
- [2] UCI Machine Learning Repository, "Estimation of Obesity Levels Based on Eating Habits and Physical Condition", 2019. Disponible en: <https://archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition>.
- [3] T. Cui, Y. Chen, J. Wang, H. Deng and Y. Huang, "Estimation of Obesity Levels Based on Decision Trees," in *2021 International Symposium on Artificial Intelligence and its Application on Media (ISAIAM)*, Xi'an, China, 2021, pp. 160–165, doi: 10.1109/ISAIAM53259.2021.00041.

- [4] M. Karakoç and Ö. F. Oruç, "Prediction of Obesity Levels Based on Eating Habits and Physical Conditions Using Machine Learning," in *2024 Innovations in Intelligent Systems and Applications Conference (ASYU)*, Ankara, Türkiye, 2024, pp. 1–5, doi: 10.1109/ASYU62119.2024.10757124.
- [5] H. G. Gozukara Bag et al., "Estimation of Obesity Levels through the Proposed Predictive Approach Based on Physical Activity and Nutritional Habits," *Diagnostics*, vol. 13, no. 18, p. 2949, Sep. 2023, doi: 10.3390/diagnostics13182949.
- [6] J. P. S. Quiroz, "Estimation of obesity levels based on dietary habits and condition physical using computational intelligence," *Informatics in Medicine Unlocked*, vol. 29, p. 100901, 2022.